Laboratorium 3

Interpolacja

Autorzy:

Kacper Hawro, Jan Ślosarczyk

01.04.2026

---

1. Zadanie 1

1.1. Treść zadania

Dane są następujące punkty opisujące populację Stanów Zjednoczonych na przestrzeni lat:

Rok	**Populacja**
1900	76 212 168
1910	92 228 496
1920	106 021 537
1930	123 202 624
1940	132 164 569
1950	151 325 798
1960	179 323 175
1970	203 302 031
1980	226 542 199

Rozważamy cztery zbiory funkcji bazowych $\varphi_j(t)$, $j = 1, ..., 9$:

$$\varphi_j(t) = t^{j-1} \qquad \varphi_j(t) = (t - 1900)^{j-1} \tag{1}$$

$$\varphi_j(t) = (t - 1940)^{j-1} \qquad \varphi_j(t) = \left(\frac{t - 1940}{40}\right)^{j-1} \tag{2}$$

Zadanie obejmuje: (a) budowę macierzy Vandermonde'a dla każdej bazy, (b) obliczenie współczynnika uwarunkowania, (c) wyznaczenie współczynników wielomianu przy użyciu najlepiej uwarunkowanej bazy i narysowanie wykresu z użyciem schematu Hornera, (d) ekstrapolację do roku 1990 i obliczenie błędu względnego, (e) wyznaczenie wielomianu Lagrange'a, (f) wyznaczenie wielomianu Newtona, (g) analizę wpływu zaokrąglenia danych do miliona.

1.2. Rozwiązanie

1.2.1. Podpunkt (a): Macierze Vandermonde'a

Dla każdej z czterech baz konstruujemy macierz Vandermonde'a V rozmiaru 9×9, gdzie element na pozycji (i, j) wynosi $\varphi_{j(t_i)}$. W implementacji wykorzystano mechanizm broadcastingu biblioteki NumPy:

```
exponent = np.array([0, 1, 2, 3, 4, 5, 6, 7, 8])

V_1 = dates[:, np.newaxis] ** exponent                    # baza 1
V_2 = (dates - 1900)[:, np.newaxis] ** exponent          # baza 2
```

```
V_3 = (dates - 1940)[:, np.newaxis] ** exponent          # baza 3
V_4 = ((dates - 1940) / 40)[:, np.newaxis] ** exponent   # baza 4
```

Dla zobrazowania wynikowej struktury, poniżej przedstawiono macierz V_4 dla najlepiej uwarunkowanej Bazy 4 (wartości zaokrąglone do 2 miejsc po przecinku). Widać na niej wyraźnie, jak przeskalowanie węzłów czasowych (lat) do przedziału bliskiego $[-1, 1]$ zapobiega powstawaniu gigantycznych rzędów wielkości przy wyższych potęgach:

$$V_4 = \begin{pmatrix} 1 & -1 & 1 & -1 & 1 & -1 & 1 & -1 & 1 \\ 1 & -0.75 & 0.56 & -0.42 & 0.32 & -0.24 & 0.18 & -0.13 & 0.1 \\ 1 & -0.5 & 0.25 & -0.12 & 0.06 & -0.03 & 0.02 & -0.01 & 0 \\ 1 & -0.25 & 0.06 & -0.02 & 0 & 0 & 0 & 0 & 0 \\ 1 & 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 \\ 1 & 0.25 & 0.06 & 0.02 & 0 & 0 & 0 & 0 & 0 \\ 1 & 0.5 & 0.25 & 0.12 & 0.06 & 0.03 & 0.02 & 0.01 & 0 \\ 1 & 0.75 & 0.56 & 0.42 & 0.32 & 0.24 & 0.18 & 0.13 & 0.1 \\ 1 & 1 & 1 & 1 & 1 & 1 & 1 & 1 & 1 \end{pmatrix} \tag{3}$$

1.2.2. Podpunkt (b): Współczynniki uwarunkowania

Współczynnik uwarunkowania $\kappa(V)$ macierzy mierzy czułość rozwiązania układu równań na zaburzenia danych wejściowych. Duże κ oznacza słabe uwarunkowanie i potencjalną utratę precyzji numerycznej.

Obliczone wartości przy użyciu funkcji `numpy.linalg.cond`:

Baza	**Wzór**	$\boldsymbol{\kappa(V)}$
Baza 1	t^{j-1}	$\approx 2.59 \times 10^{26}$
Baza 2	$(t-1900)^{j-1}$	$\approx 5.76 \times 10^{15}$
Baza 3	$(t-1940)^{j-1}$	$\approx 9.32 \times 10^{12}$
Baza 4	$\left(\frac{t-1940}{40}\right)^{j-1}$	$\approx 1.61 \times 10^{3}$

Najlepiej uwarunkowana jest **Baza 4**, która centruje i skaluje dane tak, że węzły interpolacji leżą w przedziale $[-1, 1]$. Baza 1 jest skrajnie źle uwarunkowana ze względu na ogromne potęgi liczb rzędu 10^3.

1.2.3. Podpunkt (c): Schemat Hornera i wykres wielomianu

Używając najlepiej uwarunkowanej Bazy 4, rozwiązujemy układ $V_4\boldsymbol{a} = \boldsymbol{y}$, aby wyznaczyć współczynniki wielomianu interpolacyjnego.

Do efektywnego obliczania wartości wielomianu zastosowano **schemat Hornera**, który minimalizuje liczbę mnożeń. Dla bazy skalowanej $\frac{t-1940}{40}$ schemat przyjmuje postać:

$$p(t) = a_0 + s(a_1 + s(a_2 + s(... + s \cdot a_8 ...))), \quad s = \frac{t - 1940}{40} \tag{4}$$

```
def horner_scheme(year, coeffs):
    scaled = (year - 1940) / 40
    res = 0
    for i in range(len(coeffs) - 1, -1, -1):
        res = res * scaled + coeffs[i]
    return res
```

Wartości wielomianu zostały obliczone w odstępach jednorocznych na przedziale $[1900, 1990]$.

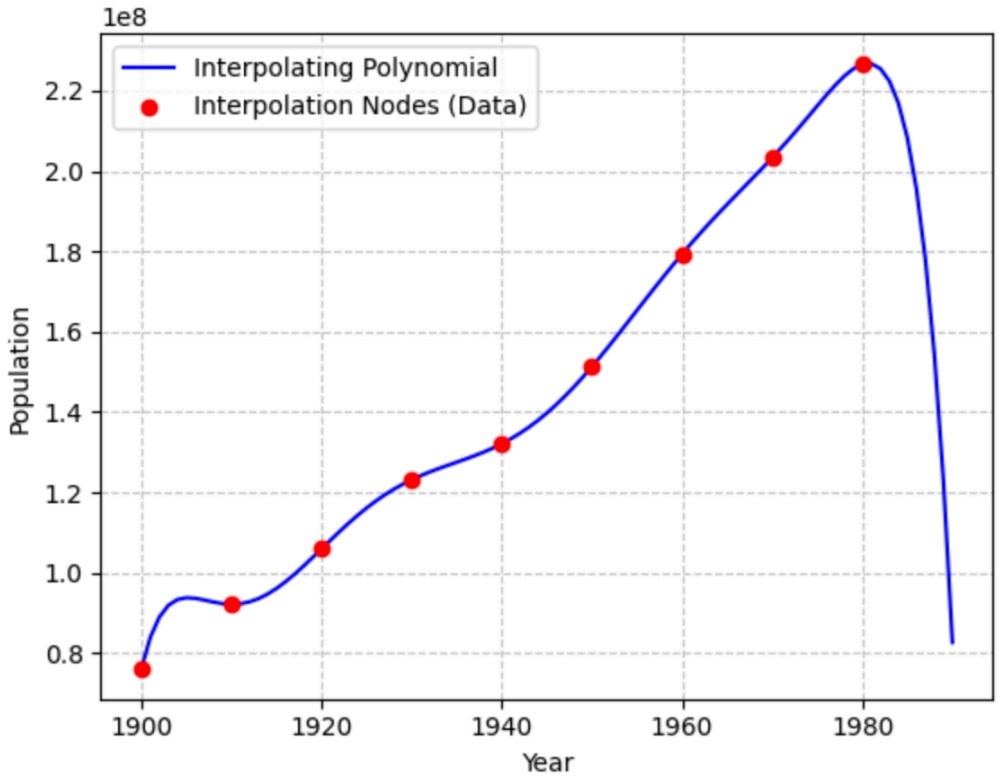

Rysunek 1: Wielomian interpolacyjny z węzłami

Wyznaczone współczynniki wielomianu (dla Bazy 4) prezentują się następująco:

Współczynnik	**Wartość**
a_0	1.32164569×10^8
a_1	4.61307656×10^7
a_2	1.02716315×10^8
a_3	1.82527130×10^8
a_4	-3.74614715×10^8
a_5	-3.42668456×10^8

a_6	6.06291250×10^8
a_7	1.89175576×10^8
a_8	-3.15180235×10^8

1.2.4. Podpunkt (d): Ekstrapolacja do roku 1990

Wielomian interpolacyjny wyznaczony na podstawie danych z lat 1900–1980 użyty został do ekstrapolacji populacji dla roku 1990. Prawdziwa wartość populacji USA w 1990 r. wynosiła 248 709 873.

Błąd względny ekstrapolacji definiujemy jako:

$$E_{\text{rel}} = \frac{|y_{\text{true}} - y_{\text{pred}}|}{y_{\text{true}}} \tag{5}$$

Otrzymane wyniki:

Wartość przewidywana (1990)	82 749 141
Wartość prawdziwa (1990)	248 709 873
Błąd względny	$\approx 66.73\%$

Tak duży błąd ekstrapolacji jest typowym zjawiskiem dla wielomianów wysokiego stopnia — poza przedziałem interpolacji mogą one zachowywać się bardzo nieregularnie (efekt Rungego).

1.2.5. Podpunkt (e): Wielomian interpolacyjny Lagrange'a

Wielomian Lagrange'a wyznaczamy bezpośrednio z definicji wielomianów bazowych $l_{j(t)}$:

$$p(t) = \sum_{j=0}^{n} y_j \cdot l_{j(t)}, \quad l_{j(t)} = \prod_{i \neq j} \frac{t - t_i}{t_j - t_i} \tag{6}$$

```
def lagrange_interpolation(x_nodes, y_nodes, x_eval):
    y_eval = np.zeros_like(x_eval, dtype=float)
    n = len(x_nodes)
    for i in range(n):
        L_i = np.ones_like(x_eval, dtype=float)
        for j in range(n):
            if i != j:
                L_i *= (x_eval - x_nodes[j]) / (x_nodes[i] - x_nodes[j])
        y_eval += y_nodes[i] * L_i
    return y_eval
```

Metoda ta wyznacza ten sam wielomian co podejście przez macierz Vandermonde'a, lecz wymaga $O(n^2)$ operacji na punkt ewaluacji. Wyniki dla wybranych lat:

Rok	Wartość (Lagrange)	Wartość prawdziwa
1950	151 325 798	151 325 798
1990	82 749 141	248 709 873

Zgodność w węźle interpolacji (1950) potwierdza poprawność implementacji.

1.2.6. Podpunkt (f): Wielomian interpolacyjny Newtona

Wielomian Newtona wyznaczamy przy pomocy **ilorazów różnicowych**. Tablica ilorazów różnicowych $\left[t_i, ..., t_{\{i+k\}}\right]$ definiowana jest rekurencyjnie:

$$[t_i] = y_i, \quad \left[t_i, ..., t_{\{i+k\}}\right] = \frac{\left[t_{\{i+1\}}, ..., t_{\{i+k\}}\right] - \left[t_i, ..., t_{\{i+k-1\}}\right]}{t_{\{i+k\}} - t_i} \tag{7}$$

Postać Newtona wielomianu:

$$p(t) = [t_0] + [t_0, t_1](t - t_0) + [t_0, t_1, t_2](t - t_0)(t - t_1) + ... \tag{8}$$

```
def divided_differences(x, y):
    n = len(y)
    coef = np.zeros([n, n])
    coef[:, 0] = y
    for j in range(1, n):
        for i in range(n - j):
            coef[i][j] = (coef[i+1][j-1] - coef[i][j-1]) / (x[i+j] - x[i])
    return coef[0, :]

def newton_interpolation(x_nodes, coeffs, x_eval):
    n = len(coeffs)
    res = coeffs[n-1]
    for i in range(n-2, -1, -1):
        res = res * (x_eval - x_nodes[i]) + coeffs[i]
    return res
```

Predykcja dla roku 1990 wynosi 82 749 141 — identycznie jak w metodzie Lagrange'a i Vandermonde'a, co potwierdza, że wszystkie trzy metody wyznaczają ten sam wielomian interpolacyjny ósmego stopnia.

1.2.7. Podpunkt (g): Wpływ zaokrąglenia danych

Dane populacyjne zaokrąglono do najbliższego miliona. Zaokrąglone wartości populacji:

Rok	Oryginał	Zaokrąglone
1900	76 212 168	76 000 000
1940	132 164 569	132 000 000
1980	226 542 199	227 000 000

Zgodnie z poleceniem wyznaczono nowe współczynniki wielomianu dla najlepiej uwarunkowanej Bazy 4. Poniższa tabela prezentuje bezpośrednie porównanie współczynników przed i po zaokrągleniu danych:

Współczynnik	Przed zaokrągleniem (c)	Po zaokrągleniu (g)	Różnica
a_0	1.3216×10^8	1.3200×10^8	1.6457×10^5
a_1	4.6131×10^7	4.5957×10^7	1.7362×10^5
a_2	1.0272×10^8	1.0014×10^8	2.5750×10^6
a_3	1.8253×10^8	1.8111×10^8	1.4160×10^6
a_4	-3.7461×10^8	-3.5676×10^8	-1.7859×10^7
a_5	-3.4267×10^8	-3.3849×10^8	-4.1796×10^6
a_6	6.0629×10^8	5.7031×10^8	3.5980×10^7
a_7	1.8918×10^8	1.8692×10^8	2.2549×10^6
a_8	-3.1518×10^8	-2.9420×10^8	-2.0983×10^7

Wyjaśnienie wyniku: Pomimo że zaokrąglenie danych o zaledwie ok. 0.1–0.5% zmienia dane wejściowe w bardzo niewielkim stopniu, różnice w skrajnych współczynnikach sięgają nawet rzędu 10^7. Wynika to z faktu, że dla wielomianów wysokiego stopnia, nawet relatywnie niewielkie zaburzenie zostaje mocno wzmocnione przez sam układ równań (mimo zastosowania najlepiej uwarunkowanej Bazy 4, której współczynnik uwarunkowania to nadal $\kappa \approx 1600$).

Błąd względny ekstrapolacji dla roku 1990 obliczony na podstawie zaokrąglonych danych:

- **Przewidywana populacja:** 109 000 000
- **Błąd względny:** 56.17%

Wynik predykcji zmienił się aż o ponad 26 milionów w porównaniu do modelu opartego na oryginalnych danych (82 749 141), co ostatecznie udowadnia niestabilność i wrażliwość tego wielomianu.

1.3. Wnioski

Zadanie pokazało, że wybór bazy funkcji interpolacyjnych ma kluczowe znaczenie dla stabilności numerycznej. Baza skalowana i centrowana (Baza 4) jest o ponad 10^{23} razy lepiej uwarunkowana od bazy monomialnej (Baza 1), co bezpośrednio przekłada się na dokładność wyznaczonych współczynników.

Wszystkie trzy metody (Vandermonde, Lagrange, Newton) wyznaczają ten sam wielomian interpolacyjny — różnią się jedynie reprezentacją i kosztem obliczeniowym. Schemat Hornera pozwala na efektywną ewaluację wielomianu przy minimalnej liczbie operacji arytmetycznych.

Ekstrapolacja do roku 1990 daje błąd rzędu 66.73%, co ilustruje typowy problem wielomianów wysokiego stopnia: wewnątrz przedziału interpolacji zachowują się dobrze, natomiast poza nim mogą gwałtownie odbiegać od rzeczywistości (efekt Rungego). Jest to argument za stosowaniem interpolacji lokalnej (np. funkcji sklejanych) dla danych, dla których ekstrapolacja jest istotna.

2. Zadanie 2: Roczna produkcja cytrusów we Włoszech

2.1. Treść zadania

Roczna produkcja cytrusów we Włoszech kształtowała się następująco:

Rok	**Produkcja [10^5 kg]**
1965	17 769
1970	24 001
1980	25 961
1985	34 336
1990	29 036
1991	33 417

Zadanie wymaga:

1. Użycia kubicznych funkcji sklejanych (splajnów 3. stopnia) różnych rodzajów, aby oszacować produkcję w latach 1962, 1977 oraz 1992.
2. Porównania otrzymanych wyników z wartościami prawdziwymi, które wynosiły odpowiednio: 12 380, 27 403 oraz 32 059.
3. Powtórzenia analizy, używając globalnego wielomianu interpolacyjnego Lagrange'a.

2.2. Rozwiązanie

2.2.1. Szacowanie za pomocą kubicznych funkcji sklejanych

Kubiczne funkcje sklejane (splajny) dzielą przedział na podprzedziały i na każdym z nich definiują osobny wielomian 3. stopnia. Wymagają one podania dodatkowych warunków brzegowych na końcach dziedziny. Do analizy wykorzystano implementację biblioteki `scipy.interpolate.CubicSpline` i przetestowano trzy warianty:

- **not-a-knot** – zakłada, że trzecia pochodna jest ciągła w pierwszym i ostatnim węźle wewnętrznym.
- **natural** – wymusza zerowanie się drugiej pochodnej na brzegach przedziału, co fizycznie odpowiada „wypłaszczaniu" się krzywej na skrajach.
- **clamped** – wymusza zerowanie pierwszej pochodnej na brzegach: $S_0'(a) = S_0'(b) = 0$, co oznacza, że krzywa wchodzi w skrajne węzły idealnie poziomo.

2.2.2. Szacowanie za pomocą wielomianu Lagrange'a

W celu zbudowania punktu odniesienia wyznaczono tradycyjny, globalny wielomian interpolacyjny Lagrange'a (stopnia 5, ponieważ badamy 6 węzłów). Obliczono jego wartości w badanych latach w celu weryfikacji precyzji wewnątrz przedziału (interpolacja: rok 1977) oraz na zewnątrz (ekstrapolacja: lata 1962 i 1992).

2.2.3. Zestawienie wyników i błędów

Poniższa tabela prezentuje produkcję przewidywaną przez poszczególne modele oraz ich błędy względne w stosunku do wartości prawdziwych.

Rok	**Prawdziwa produkcja**	**Splajn (not-a-knot)**	**Splajn (naturalny)**	**Splajn (clamped)**	**Wielomian Lagrange'a**
1962	12 380	5 146 (Błąd: 58.43%)	13 285 (Błąd: 7.31%)	24 313 (Błąd: 96.39%)	−77 823 (Błąd: 728.62%)
1977	27 403	22 642 (Błąd: 17.37%)	22 934 (Błąd: 16.31%)	23 126 (Błąd: 15.61%)	15 342 (Błąd: 44.01%)
1992	32 059	41 894 (Błąd: 30.68%)	37 798 (Błąd: 17.90%)	22 166 (Błąd: 30.86%)	43 062 (Błąd: 34.32%)

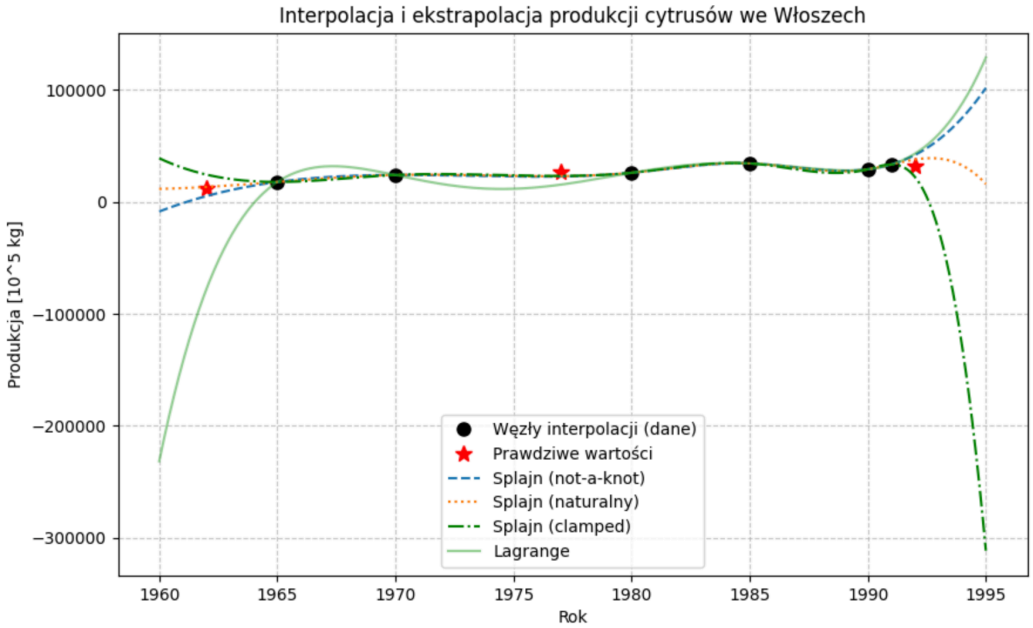

Rysunek 2: Interpolacja i ekstrapolacja produkcji cytrusów we Włoszech przy użyciu różnych modeli.

2.3. Wnioski

1. **Wielomian globalny a zjawisko Rungego:** Zgodnie z wynikami z tabeli, zastosowanie globalnego wielomianu Lagrange'a kończy się całkowitą porażką analityczną. Przy próbie ekstrapolacji w przeszłość (rok 1962) wielomian zachowuje się drastycznie niestabilnie, zwracając absurdalną wartość ujemną (błąd aż 728.62%). Dodatkowo, nawet przy interpolacji wewnątrz przedziału (rok 1977), błąd wyniósł ponad 44%. Bezpośrednio demonstruje to niszczycielski wpływ zjawiska Rungego na brzegach dziedziny oraz niestabilność wielomianów wysokich stopni.
2. **Zdecydowana przewaga Splajnów:** Kubiczne funkcje sklejane okazały się znacznie bardziej zachowawcze i odporne na dzikie oscylacje poza przedziałem interpolacyjnym. W każdym z badanych lat (zarówno podczas interpolacji, jak i ekstrapolacji) wygenerowały one mniejszy błąd niż model Lagrange'a.
3. **Pułapka splajnu usztywnionego (clamped):** Pomimo że splajn typu clamped poradził sobie świetnie wewnątrz przedziału (w 1977 roku błąd wyniósł zaledwie 15.61%), zawiódł

przy ekstrapolacji. Domyślne narzucenie zerowej pierwszej pochodnej na brzegach zmusiło krzywą o wyraźnym trendzie do nienaturalnego, poziomego wypłaszczenia w skrajnych węzłach. Przez to sztuczne zaburzenie model drastycznie i nienaturalnie opadł poza przedziałem, generując ogromny błąd dla 1962 roku (ponad 96.39%).

4. **Splajn naturalny jako najlepszy model:** Bezkonkurencyjnym zwycięzcą zestawienia jest splajn naturalny. Wymuszenie zerowania się drugiej pochodnej na brzegach przedziału (brak zakrzywienia, „wypłaszczenie" krzywej) sprawiło, że genialnie poradził on sobie z ekstrapolacją – dla 1962 roku pomylił się zaledwie o 7.31%, a dla 1992 roku o 17.90%. Uodparnia to model na gwałtowne wahania, czyniąc funkcje sklejane naturalne o wiele potężniejszym i bezpieczniejszym narzędziem dla rzeczywistych zbiorów danych niż jakikolwiek globalny wielomian.